

Attention Is All You Need

authors: Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin

affiliation: Google Brain, Google Research, University of Toronto

venue: NeurIPS 2017

source: [arXiv:1706.03762v7](https://arxiv.org/abs/1706.03762v7)

TL;DR

本文提出了Transformer网络结构，通过完全基于self-attention机制，摒弃了以往的循环神经网络（RNN）和卷积网络（CNN），显著提升了序列到序列建模尤其是机器翻译的质量与效率。Transformer模型能更好地并行计算，训练速度快，且基于attention的方法易于扩展到其它任务。核心创新为用多头自注意力机制（multi-head self-attention）取代所有复杂的时序依赖结构，并通过指标优势和实验结果成为新的序列建模范式。

引言

传统的序列到序列模型主要依赖于循环神经网络（RNN）、长短时记忆网络（LSTM）以及门控循环网络（GRU），这些模型通过时间步递归方式处理输入序列和输出序列，但受制于顺序计算，难以充分并行化，尤其在长序列依赖上存在效率瓶颈。

最近逐渐流行的attention机制，允许模型无需关心序列距离即可捕捉输入输出间的依赖关系，提高了模型的表现。但之前的工作通常将attention与RNN结合使用。

本文首次完全舍弃RNN和CNN，提出了Transformer架构——依赖堆叠的自注意力（self-attention）和点式前馈网络（point-wise feed-forward network），能够有效地处理长距离依赖，并极大提升训练速度和模型表现。


方法

Transformer架构

Transformer由一个Encoder-Decoder结构组成，全部基于self-attention和前馈网络构建。Encoder和Decoder均包含多层（通常为6层），每层都有multi-head attention与前馈子层。Decoder层则额外使用masked multi-head attention以实现自回归生成。

模型架构总览

如下图所示，Transformer架构完全依赖attention作为核心连接机制：



Transformer模型结构示意图：左为Encoder堆叠，右为Decoder堆叠，两者均包含多头自注意力和前馈神经网络。

架构要点： - **Encoder**： 每一层包括多头自注意力、前馈网络、add & norm。 - **Decoder**： 除了encoder结构，额外包含masked multi-head attention防止泄露未来信息，并与encoder输出结合（cross-attention）。 - 位置编码（**Positional Encoding**）： 用于保留序列顺序信息，以弥补attention机制中无序结构。

Attention机制


注意力函数定义为映射一个query及一组key-value对到输出，具体采用Scaled Dot-Product Attention:

$$Attention(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

其中， Q （Query）， K （Key）， V （Value）均为向量， d_k 为Key向量维度。

Multi-Head Attention

多个attention头并行计算，提升模型捕捉不同语义和结构信息能力。每个头独立计算attention后其输出串联（concat）起来，再通过线性变换。



*Scaled Dot-Product Attention和Multi-Head Attention结构示意图。左图
为单头attention的计算流程，右图为多头attention的并行机制。*

multi-head attention公式如下：

$$MultiHead(Q, K, V) = \text{Concat}(head_1, ..., head_h)W^O$$

其中 $head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$ 。

前馈神经网络（Feed-Forward Networks）

每层attention后接一个两层前馈网络，形式为：

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

位置编码

通过正弦和余弦函数生成不同频率的向量，加到输入的embedding上，以确保模型能区分不同序列位置。

各层复杂度与路径长度对比

Transformer中的self-attention机制能够在常数步并行完成操作，而RNN需要依次序列处理：

Layer Type	Complexity per Layer	Sequential Operations	Maximum Path Length
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k(n))$
Self-Attention (restricted)	$O(r \cdot n \cdot d)$	$O(1)$	$O(n/r)$

不同layer类型的复杂度和最大路径长度对比。

实验

数据集与设置

- WMT 2014 英德（EN-DE）、英法（EN-FR）机器翻译任务
- Penn Treebank用于英语语法 constituency parsing
- 训练硬件为8块NVIDIA P100 GPU

模型与评价指标

- BLEU分数（机器翻译质量）
- 训练复杂度（FLOPs）

结果

翻译任务结果（BLEU与训练复杂度）

Transformer（base model）与Transformer（big）在BLEU分数和训练效率上均大幅优于现有最优模型：

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	41.29	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	$3.3 \cdot 10^{18}$	
Transformer (big)	28.4	41.8	$2.3 \cdot 10^{19}$	

主流方法与Transformer在翻译任务上的BLEU分数和训练复杂度对比，Transformer取得最高BLEU并且训练成本更低。

架构变体影响

模型参数、attention头数等对性能的影响如下表所示：

	N	d_{model}	d_{ff}	h	d_k	d_v	P_{drop}	ϵ_{ls}	train steps	PPL (dev)	BLEU (dev)	params $\times 10^6$
base	6	512	2048	8	64	64	0.1	0.1	100K	4.92	25.8	65
(A)				1	512	512				5.29	24.9	
				4	128	128				5.00	25.5	
				16	32	32				4.91	25.8	
				32	16	16				5.01	25.4	
(B)				16						5.16	25.1	58
				32						5.01	25.4	60
(C)	2									6.11	23.7	36
	4									5.19	25.3	50
	8									4.88	25.5	80
		256			32	32				5.75	24.5	28
		1024			128	128				4.66	26.0	168
			1024							5.12	25.4	53
			4096							4.75	26.2	90
(D)							0.0			5.77	24.6	
							0.2			4.95	25.5	
								0.0		4.67	25.3	
								0.2		5.47	25.7	
(E)		positional embedding instead of sinusoids								4.92	25.7	
big	6	1024	4096	16			0.3		300K	4.33	26.4	213

不同模型变体参数对性能的影响，BLEU和PPL作为评价指标。

语法分析任务结果

Transformer也能迁移到英语 constituency parsing 任务，取得接近或超过有监督和半监督SOTA:

4: The Transformer generalizes well to English constituency parsing (Results are on Sec 3J)


Parser	Training	WSJ 23 F1
Vinyals & Kaiser et al. (2014) [37]	WSJ only, discriminative	88.3
Petrov et al. (2006) [29]	WSJ only, discriminative	90.4
Zhu et al. (2013) [40]	WSJ only, discriminative	90.4
Dyer et al. (2016) [8]	WSJ only, discriminative	91.7
Transformer (4 layers)	WSJ only, discriminative	91.3
Zhu et al. (2013) [40]	semi-supervised	91.3
Huang & Harper (2009) [14]	semi-supervised	91.3
McClosky et al. (2006) [26]	semi-supervised	92.1
Vinyals & Kaiser et al. (2014) [37]	semi-supervised	92.1
Transformer (4 layers)	semi-supervised	92.7
Luong et al. (2015) [23]	multi-task	93.0
Dyer et al. (2016) [8]	generative	93.3

英语语法 constituency parsing 的F1分数对比，Transformer表现优异。

attention可视化

Transformer的attention机制能捕捉长距离依赖，模型对输入序列结构有很好的解释性：

Attention Visualizations



attention可视化示例，展示模型如何关注长距离依赖关系。

总结与讨论

本文提出了Transformer序列建模框架，完全基于多头自注意力机制，实现高效并行、易扩展的架构。实验结果表明，在大规模机器翻译任务上，Transformer能以更低训练成本取得SOTA性能；在语法分析等其它NLP任务上同样具备强大的泛化能力。

Transformer的优势体现在： - 更优的长距离依赖建模能力 - 性能、效率双提升 - 可视觉解释性好

局限性与未来工作： - 对于超长序列，**self-attention**复杂度较高，可进一步研究局部/稀疏**attention** - **Transformer**的无序结构可能在某些任务中需更强的位置编码设计 - 模型可推广至多模态（视觉、音频等）和更广泛序列处理任务

本文奠定了后续**BERT**、**GPT**等**pretrained transformer**模型的理论基础，是**NLP**和深度学习领域里极具里程碑意义的工作。

参考代码

代码实现可参考：<https://github.com/tensorflow/tensor2tensor>
