

Attention Is All You Need

title: “Attention Is All You Need”; **authors:** Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin; **affiliation:** Google Brain, Google Research, University of Toronto; **venue:** 31st Conference on Neural Information Processing Systems (NIPS 2017), Long Beach, CA, USA; **source:** arXiv:1706.03762v7 [cs.CL] 2 Aug 2023

TL;DR

本文提出了 **Transformer**，一种完全基于注意力机制（attention mechanism）的新型神经网络架构，摒弃了循环（RNN）和卷积（CNN）结构。其核心是缩放点积注意力（Scaled Dot-Product Attention）和多头注意力（Multi-Head Attention），通过并行计算实现了极高的训练效率。在机器翻译任务上，Transformer 不仅取得了当时最优的 BLEU 分数（EN-DE: 28.4, EN-FR: 41.8），而且训练时间大幅缩短（仅需 3.5 天）。更重要的是，该模型展现出强大的泛化能力，在英语句法依存分析等非翻译任务上也取得了突破性成果，为后续大模型时代奠定了基石。

引言

传统的序列建模与转导模型（如机器翻译）主要依赖于循环神经网络（RNN）或卷积神经网络（CNN）作为编码器-解码器结构的核心组件。然而，这些模型存在固有缺陷：1. 顺序计算：RNN 的递归特性使其难以并行化，训练速度慢，尤其在长序列上受限于内存带宽。2. 长距离依赖建模困难：尽管 LSTM/GRU 等门控机制有所改善，但信号仍需逐层传递，导致远距离位置间的依赖关系建模效率低下。

为解决上述问题，本文提出了一种全新的架构——**Transformer**。其核心思想是：完全摒弃递归与卷积，仅依靠自注意力（**Self-Attention**）机制来建模输入与输出序列中任意两个位置之间的全局依赖关系。这使得模型能够并行处理所有位置，极大地提升了计算效率，并从根本上解决了长距离依赖问题。

方法

核心架构

Transformer 的整体架构如图 1 所示，由堆叠的编码器（Encoder）和解码器（Decoder）组成，两者均由 $N=6$ 个相同的层构成。

- 编码器（**Encoder**）：每一层包含两个子层：
 1. 多头自注意力机制（Multi-Head Self-Attention）：用于捕获输入序列内部的依赖关系。




Figure 1: Figure 1: The Transformer - model architecture.

2. 前馈神经网络 (Feed-Forward Network): 一个简单的全连接前馈网络。每个子层后都接有残差连接 (Residual Connection) 和层归一化 (Layer Normalization)。
- 解码器 (**Decoder**): 每一层包含三个子层:
 1. 掩码多头自注意力机制 (Masked Multi-Head Self-Attention): 防止当前位置关注到未来的位置, 以维持自回归属性。
 2. 多头注意力机制 (Multi-Head Attention): 其 **Query** 来自解码器的前一层, 而 **Key** 和 **Value** 则来自编码器的输出, 实现对编码器信息的“交叉注意”。
 3. 前馈神经网络 (Feed-Forward Network)。同样, 每个子层后均有残差连接和层归一化。

关键组件详解

1. 缩放点积注意力 (Scaled Dot-Product Attention) 这是 Transformer 中最基础的注意力计算单元, 如图 2 (左) 所示。给定查询 (Query) 矩阵 Q 、键 (Key) 矩阵 K 和值 (Value) 矩阵 V , 其计算公式为:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

其中, d_k 是键向量的维度。引入 $\frac{1}{\sqrt{d_k}}$ 的缩放因子是为了防止点积结果过大, 导致 softmax 函数进入梯度极小的饱和区, 从而影响训练稳定性。

2. 多头注意力 (Multi-Head Attention) 为了使模型能够同时关注来自不同表示子空间的信息, Transformer 采用了多头机制。它将输入线性投影到 h 个不同的子空间, 然后在每个子空间上并行地执行缩放点积注意力, 最后将结果拼接并再次线性投影。其公式为:

$$\begin{aligned} \text{MultiHead}(Q, K, V) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \\ \text{where } \text{head}_i &= \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \end{aligned}$$

文中采用 $h = 8$ 个头, 且为保持总计算量不变, 每个头的维度 $d_k = d_v = d_{\text{model}}/h = 64$ 。

3. 位置编码 (Positional Encoding) 由于模型本身不具备对序列顺序的感知能力, 作者引入了正弦/余弦函数构成的位置编码 (Positional Encoding) 来注入位置信息:

$$\begin{aligned} PE_{(pos, 2i)} &= \sin(pos/10000^{2i/d_{\text{model}}}) \\ PE_{(pos, 2i+1)} &= \cos(pos/10000^{2i/d_{\text{model}}}) \end{aligned}$$




Figure 2: Figure 2: (left) Scaled Dot-Product Attention. (right) Multi-Head Attention consists of several attention layers running in parallel.

其中, pos 是位置, i 是维度。这种设计允许模型通过线性变换轻松学习到相对位置关系。

4. 前馈网络与嵌入 每个位置的前馈网络 (FFN) 是一个两层的全连接网络, 中间使用 ReLU 激活:

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

输入和输出的词嵌入 (Embedding) 维度为 $d_{\text{model}} = 512$, 并与位置编码相加后输入模型。最终的输出通过一个线性变换和 Softmax 得到词表上的概率分布。

模型复杂度分析

如表 1 所示, Transformer 的自注意力层具有 $O(n^2 \cdot d)$ 的计算复杂度, 但其最大路径长度仅为 $O(1)$, 这意味着任意两个位置间的依赖关系都可以一步建立, 这是其能高效建模长距离依赖的关键。相比之下, RNN 的最大路径长度为 $O(n)$, CNN 为 $O(\log_k(n))$ 。

Layer Type	Complexity per Layer	Sequential Operations	Maximum Path Length
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k(n))$
Self-Attention (restricted)	$O(r \cdot n \cdot d)$	$O(1)$	$O(n/r)$

实验

实验设置

- 数据集: WMT 2014 英德 (EN-DE) 和英法 (EN-FR) 翻译任务。
- 硬件: 8 块 NVIDIA P100 GPU。
- 优化器: Adam 优化器, $\beta_1 = 0.9, \beta_2 = 0.98, \epsilon = 10^{-9}$ 。
- 训练策略: 采用带预热 (warmup) 的学习率调度策略。

主要结果

1. 机器翻译性能 (Table 2) Transformer 在两个翻译任务上均显著超越了当时的 SOTA 模型, 且训练成本更低。

Model	EN-DE BLEU	EN-FR BLEU	Training Cost (FLOPs)
Transformer (big)	28.4	41.8	$2.3 \cdot 10^{19}$
ConvS2S Ensemble [9]	26.36	41.29	$1.2 \cdot 10^{21}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.1 \cdot 10^{21}$

- 关键结论：Transformer (big) 在 EN-FR 任务上达到了 41.8 的 BLEU 分数，刷新了记录；其训练成本仅为之前最佳集成模型的约 1/50。

2. 架构消融实验 (Table 3) 表 3 系统地验证了各超参数的影响：* 头数 ($\mathbf{h}$): 8 头为最优，过少 (1, 4) 或过多 (16, 32) 都会导致性能下降。* 维度 (d_k, d_v): 减小维度会损害模型质量，印证了点积注意力的兼容性函数需要足够维度才能有效工作。* **Dropout**: 加入 dropout (0.1) 能有效防止过拟合，提升泛化性能。* 位置编码: 将正弦位置编码替换为可学习的编码，效果几乎相同，说明其设计是合理的。


3. 泛化能力验证：英语句法依存分析 (Table 4) 为证明 Transformer 的通用性，作者将其应用于英语句法依存分析 (English Constituency Parsing) 任务。

Model	WSJ 23 F1
Transformer (4 layers)	92.7
Luong et al. (2015) [23]	93.0
Dyer et al. (2016) [8]	93.3

- 关键结论：即使只用 4 层、仅在 40K 句子的小规模数据集上进行无监督预训练 (WSJ only, discriminative)，Transformer 也取得了 91.3 的 F1 分数，接近甚至超过了当时最先进的 RNN 模型。这强有力地证明了其强大的特征提取能力和模型泛化能力。

4. 注意力可视化 论文通过多个图例 (Figures 3, 4, 5) 直观展示了注意力机制的工作原理：* **Figure 3**: 展示了对动词 “making” 的长距离依赖捕捉，多个注意力头都聚焦于其宾语 “registration”。* **Figure 4 & 5**: 揭示了不同注意力头会学习到不同的语言学功能，例如有的头专注于句法结构（如解析 “The Law”），有的头则负责指代消解（如解析 “its”）。

Attention Visualizations






Figure 4: Two attention heads, also in layer 5 of 6, apparently involved in anaphora resolution. Top: Full attentions for head 5. Bottom: Isolated attentions from just the word ‘its’ for attention heads 5 and 6. Note that the attentions are very sharp for this word.




Figure 5: Many of the attention heads exhibit behaviour that seems related to the structure of the sentence. We give two such examples above, from two different heads from the encoder self-attention at layer 5 of 6. The heads clearly learned to perform different tasks.

总结与讨论

总结

本文提出的 Transformer 架构是深度学习领域的一项里程碑式工作。它通过纯粹的注意力机制，成功地解决了 RNN/CNN 在序列建模中的核心瓶颈——并行化与长距离依赖。其简洁而强大的设计不仅在机器翻译任务上取得了卓越成绩，更在句法

分析等下游任务上展现了惊人的泛化能力，彻底改变了自然语言处理的研究范式。

局限性与未来工作

- 计算与内存开销：自注意力的 $O(n^2)$ 复杂度在处理超长序列（如整篇文档、视频帧）时会成为瓶颈。论文在第 11 页也提及了这一点，并计划未来研究限制注意力范围（如只关注局部邻域）的方法。
- 对归纳偏置的削弱：完全放弃卷积和循环结构，意味着模型失去了对局部性（CNN）和顺序性（RNN）的先验知识，这可能在某些特定任务上需要更多数据来弥补。
- 未来方向：正如论文结论所述，作者计划将 Transformer 扩展到图像、音频等多模态任务，并探索更高效的注意力变体（如稀疏注意力、线性注意力）以处理更大规模的输入。后续的 BERT、GPT 等模型正是沿着这一方向发展的直接产物。

总而言之，“Attention Is All You Need”不仅是一篇提出新模型的论文，更是一份宣告新时代来临的宣言书，其影响深远，至今仍是大语言模型（LLM）架构的基石。